



UTEC Posgrado



UTEC Posgrado




MACHINE LEARNING

AGRUPAMIENTO

JERÁRQUICO

Motivación

Contexto y necesidad del agrupamiento jerárquico



Repaso: Análisis de conglomerados

Objetivo: Agrupar N objetos en subconjuntos (conglomerados) tales que:

- ▶ Objetos **dentro** de un conglomerado: muy **similares**



Repaso: Análisis de conglomerados

Objetivo: Agrupar N objetos en subconjuntos (conglomerados) tales que:

- ▶ Objetos **dentro** de un conglomerado: muy **similares**
- ▶ Objetos en conglomerados **distintos**: muy **diferentes**



Repaso: Análisis de conglomerados

Objetivo: Agrupar N objetos en subconjuntos (conglomerados) tales que:

- ▶ Objetos **dentro** de un conglomerado: muy **similares**
- ▶ Objetos en conglomerados **distintos**: muy **diferentes**

Central: La noción de **similitud** (o **disimilitud**) entre objetos, que solo puede provenir de consideraciones del dominio.



Limitaciones de K-means

- Requiere fijar K de antemano



Limitaciones de K-means

- ▶ Requiere fijar K de antemano
- ▶ Partición plana: no hay estructura anidada



Limitaciones de K-means

- ▶ Requiere fijar K de antemano
- ▶ Partición plana: no hay estructura anidada
- ▶ Al cambiar K , los clusters **no quedan anidados**



Limitaciones de K-means

- ▶ Requiere fijar K de antemano
- ▶ Partición **plana**: no hay estructura anidada
- ▶ Al cambiar K , los clusters **no quedan anidados**
- ▶ No proporciona **ordenamiento** dentro de cada cluster



Limitaciones de K-means

- ▶ Requiere fijar K de antemano
- ▶ Partición **plana**: no hay estructura anidada
- ▶ Al cambiar K , los clusters **no quedan anidados**
- ▶ No proporciona **ordenamiento** dentro de cada cluster

¿Existe una alternativa que NO requiera fijar K y que produzca una jerarquía natural?

⇒ Agrupamiento Jerárquico



¿Qué es el agrupamiento jerárquico?

Produce **representaciones jerárquicas** donde los conglomerados en cada nivel se crean fusionando (o dividiendo) los del nivel adyacente.

- ▶ **Nivel más bajo:** cada observación es un conglomerado unitario



¿Qué es el agrupamiento jerárquico?

Produce **representaciones jerárquicas** donde los conglomerados en cada nivel se crean fusionando (o dividiendo) los del nivel adyacente.

- ▶ **Nivel más bajo:** cada observación es un conglomerado unitario
- ▶ **Nivel más alto:** un único conglomerado con todos los datos



¿Qué es el agrupamiento jerárquico?

Produce **representaciones jerárquicas** donde los conglomerados en cada nivel se crean fusionando (o dividiendo) los del nivel adyacente.

- ▶ **Nivel más bajo:** cada observación es un conglomerado unitario
- ▶ **Nivel más alto:** un único conglomerado con todos los datos
- ▶ **Resultado:** un **dendrograma** (árbol binario)



¿Qué es el agrupamiento jerárquico?

Produce **representaciones jerárquicas** donde los conglomerados en cada nivel se crean fusionando (o dividiendo) los del nivel adyacente.

- ▶ **Nivel más bajo:** cada observación es un conglomerado unitario
 - ▶ **Nivel más alto:** un único conglomerado con todos los datos
 - ▶ **Resultado:** un **dendrograma** (árbol binario)
-
- ▷ Hay $N - 1$ niveles en la jerarquía para N observaciones.



Aglomerativo (bottom-up)

- Comienza con N clusters unitarios
- En cada paso: fusiona los 2 más cercanos
- $N - 1$ fusiones hasta un solo grupo



Divisivo (top-down)

- Comienza con 1 cluster global
- En cada paso: divide un cluster en 2
- $N - 1$ divisiones hasta singletons



Aplicaciones del agrupamiento jerárquico

Área	Aplicación
Genómica	Agrupamiento de genes por patrones de expresión
Taxonomía	Clasificación filogenética de especies
Procesamiento de texto	Organización jerárquica de documentos
Ciencias sociales	Agrupamiento de países por similitud política



Matrices de proximidad

Los datos se representan mediante una **matriz de disimilitudes D** de $N \times N$:

- $d_{ii'} \geq 0$: disimilitud entre objetos i e i'



Matrices de proximidad

Los datos se representan mediante una **matriz de disimilitudes** D de $N \times N$:

- ▶ $d_{ii'} \geq 0$: disimilitud entre objetos i e i'
- ▶ $d_{ii} = 0$: diagonal nula



Matrices de proximidad

Los datos se representan mediante una **matriz de disimilitudes** D de $N \times N$:

- ▶ $d_{ii'} \geq 0$: disimilitud entre objetos i e i'
- ▶ $d_{ii} = 0$: diagonal nula
- ▶ Simétrica: $d_{ii'} = d_{i'i}$



Matrices de proximidad

Los datos se representan mediante una **matriz de disimilitudes D** de $N \times N$:

- ▶ $d_{ii'} \geq 0$: disimilitud entre objetos i e i'
- ▶ $d_{ii} = 0$: diagonal nula
- ▶ Simétrica: $d_{ii'} = d_{i'i}$


Distancia más común: euclíadiana cuadrática

$$D(x_i, x_{i'}) = \sum_{j=1}^p (x_{ij} - x_{i'j})^2 = \|x_i - x_{i'}\|^2$$



Desarrollo

Agrupamiento jerárquico **Algoritmos y variantes**



Agrupamiento aglomerativo: Idea

1. Iniciar con N conglomerados unitarios (cada observación es un cluster)



Agrupamiento aglomerativo: Idea

1. Iniciar con N conglomerados unitarios (cada observación es un cluster)
2. En cada uno de los $N - 1$ pasos:
 - ▶ Encontrar los dos clusters más cercanos
 - ▶ Fusionarlos en un solo cluster



Agrupamiento aglomerativo: Idea

1. Iniciar con N conglomerados unitarios (cada observación es un cluster)
2. En cada uno de los $N - 1$ pasos:
 - ▶ Encontrar los dos clusters más cercanos
 - ▶ Fusionarlos en un solo cluster
3. Registrar la disimilitud de cada fusión



Agrupamiento aglomerativo: Idea

1. Iniciar con N conglomerados unitarios (cada observación es un cluster)
2. En cada uno de los $N - 1$ pasos:
 - ▶ Encontrar los dos clusters más cercanos
 - ▶ Fusionarlos en un solo cluster
3. Registrar la disimilitud de cada fusión
4. Resultado: un **dendrograma**



Agrupamiento aglomerativo: Idea

1. Iniciar con N conglomerados unitarios (cada observación es un cluster)
2. En cada uno de los $N - 1$ pasos:
 - ▶ Encontrar los dos clusters más cercanos
 - ▶ Fusionarlos en un solo cluster
3. Registrar la disimilitud de cada fusión
4. Resultado: un **dendrograma**

Pregunta clave: ¿Cómo definimos la distancia entre grupos?



Entrada: Matriz de disimilitudes $\{d_{ii'}\}$, método de enlace


Salida : Dendrograma (árbol de fusiones)

- 1 Inicializar N clusters: $C_i = \{x_i\}$ para $i = 1, \dots, N$
 - 2 Calcular disimilitudes entre todos los pares de clusters
 - 3 **for** $t = 1$ to $N - 1$ **do**
 - 4 Encontrar el par (C_a, C_b) con menor disimilitud intergrupal
 - 5 Fusionar: $C_{\text{new}} \leftarrow C_a \cup C_b$
 - 6 Registrar la fusión y su altura (disimilitud)
 - 7 Actualizar la matriz de disimilitudes con C_{new}
 - 8 **end**
 - 9 **return** Dendrograma con las $N - 1$ fusiones
-

Enlace simple (Single Linkage)

Disimilitud intergrupal = distancia entre el par **más cercano**:

$$d_{SL}(G, H) = \min_{\substack{i \in G \\ i' \in H}} d_{ii'}$$



Enlace simple (Single Linkage)

Disimilitud intergrupal = distancia entre el par **más cercano**:

$$d_{SL}(G, H) = \min_{\substack{i \in G \\ i' \in H}} d_{ii'}$$

► Técnica del “vecino más cercano”



Enlace simple (Single Linkage)

Disimilitud intergrupal = distancia entre el par **más cercano**:

$$d_{SL}(G, H) = \min_{\substack{i \in G \\ i' \in H}} d_{ii'}$$




- ▶ Técnica del “vecino más cercano”
- ▶ Invariante frente a transformaciones monótonas



Enlace simple (Single Linkage)

Disimilitud intergrupal = distancia entre el par **más cercano**:

$$d_{SL}(G, H) = \min_{\substack{i \in G \\ i' \in H}} d_{ii'}$$



- ▶ Técnica del “vecino más cercano”
- ▶ Invariante frente a transformaciones monótonas
- ▶ Problema: encadenamiento



Enlace completo (Complete Linkage)

Disimilitud intergrupal = distancia entre el par más lejano:

$$d_{CL}(G, H) = \max_{\substack{i \in G \\ i' \in H}} d_{ii'}$$




- ▶ Técnica del “vecino más lejano”
- ▶ Produce clusters **compactos** (diámetro pequeño)
- ▶ Invariante a transformaciones monótonas
- ▶ Puede violar “cercanía”



Enlace promedio (Group Average)

Disimilitud intergrupal = **promedio** de todas las distancias entre grupos:

$$d_{GA}(G, H) = \frac{1}{N_G \cdot N_H} \sum_{i \in G} \sum_{i' \in H} d_{ii'}$$




Enlace promedio (Group Average)

Disimilitud intergrupal = **promedio** de todas las distancias entre grupos:

$$d_{GA}(G, H) = \frac{1}{N_G \cdot N_H} \sum_{i \in G} \sum_{i' \in H} d_{ii'}$$


► Compromiso entre SL y CL



Enlace promedio (Group Average)

Disimilitud intergrupal = **promedio** de todas las distancias entre grupos:

$$d_{GA}(G, H) = \frac{1}{N_G \cdot N_H} \sum_{i \in G} \sum_{i' \in H} d_{ii'}$$




- ▶ Compromiso entre SL y CL
- ▶ No invariante a transformaciones monótonas



Enlace promedio (Group Average)

Disimilitud intergrupal = **promedio** de todas las distancias entre grupos:

$$d_{GA}(G, H) = \frac{1}{N_G \cdot N_H} \sum_{i \in G} \sum_{i' \in H} d_{ii'}$$



- ▶ Compromiso entre SL y CL
- ▶ No invariante a transformaciones monótonas
- ▶ **Consistencia estadística:** converge a una característica poblacional



Comparación de métodos de enlace

	Simple	Completo	Promedio
Fórmula	$\min d_{ii'}$	$\max d_{ii'}$	$\frac{1}{N_G N_H} \sum d_{ii'}$
Clusters	Alargados	Compactos	Intermedio
Defecto	Encadenamiento	Viola cercanía	Depende de escala
Invariancia	Sí (monótona)	Sí (monótona)	No
Consistencia	No ($\rightarrow 0$)	No ($\rightarrow \infty$)	Sí



Fenómeno de encadenamiento (Single Linkage)

Encadenamiento: puntos intermedios conectan dos clusters que deberían estar separados




El enlace simple une clusters si **un solo par** de puntos es cercano \Rightarrow produce clusters alargados y no compactos.




¿Qué es un dendrograma?

- Árbol binario que representa la jerarquía




¿Qué es un dendrograma?

- ▶ Árbol binario que representa la jerarquía
- ▶ Hojas: observaciones individuales




¿Qué es un dendrograma?

- ▶ Árbol binario que representa la jerarquía
- ▶ **Hojas:** observaciones individuales
- ▶ **Raíz:** cluster con todos los datos




¿Qué es un dendrograma?

- ▶ Árbol binario que representa la jerarquía
- ▶ **Hojas:** observaciones individuales
- ▶ **Raíz:** cluster con todos los datos
- ▶ **Altura:** disimilitud de la fusión




¿Qué es un dendrograma?

- ▶ Árbol binario que representa la jerarquía
- ▶ **Hojas:** observaciones individuales
- ▶ **Raíz:** cluster con todos los datos
- ▶ **Altura:** disimilitud de la fusión
- ▶ **Monotonidad:** la altura crece con el nivel



Cómo leer un dendrograma



- ▶ Cortar horizontalmente a una **altura** → partición en K clusters
- ▶ Fusiones a alturas altas → candidatos a clusters “naturales”
- ▶ Los clusters quedan **anidados**: $K+1$ clusters son sub-divisiones de los K



Ejemplo: Matriz de distancias

Consideremos 5 puntos con la siguiente matriz de distancias:

	A	B	C	D	E
A	0				
B	2	0			
C	6	5	0		
D	10	9	4	0	
E	9	8	5	3	0

Aplicaremos enlace simple (single linkage) paso a paso.




Ejemplo: Paso 1 — Fusión de $\{A\}$ y $\{B\}$

Mínima distancia: $d(A, B) = 2 \Rightarrow$ Fusionar $\{A, B\}$

Actualizar distancias (enlace simple):

	AB	C	D	E
AB	0			
C	5	0		
D	9	4	0	
E	8	5	3	0



$$d(AB, C) = \min(d(A, C), d(B, C)) = \min(6, 5) = 5$$



Ejemplo: Paso 2 — Fusión de $\{D\}$ y $\{E\}$

Mínima distancia: $d(D, E) = 3 \Rightarrow$ Fusionar $\{D, E\}$

Actualizar distancias:

	AB	C	DE
AB	0		
C	5	0	
DE	8	4	0



$$d(DE, C) = \min(d(D, C), d(E, C)) = \min(4, 5) = 4$$




Ejemplo: Paso 3 — Fusión de $\{C\}$ y $\{D, E\}$

Mínima distancia: $d(C, DE) = 4 \Rightarrow$ Fusionar $\{C, D, E\}$

Actualizar distancias:

	AB	CDE
AB	0	
CDE	5	0




$$d(AB, CDE) = \min(d(AB, C), d(AB, DE)) = \min(5, 8) = 5$$



Ejemplo: Paso 4 — Fusión final

Única fusión restante: $d(AB, CDE) = 5 \Rightarrow$ Fusionar todo.



Dendrograma completo con enlace simple para los 5 puntos.



Mismo ejemplo con distintos enlaces

Resultados diferentes según el método de enlace:

Paso	Single	Complete
1	$\{A, B\}$ a $h = 2$	$\{A, B\}$ a $h = 2$
2	$\{D, E\}$ a $h = 3$	$\{D, E\}$ a $h = 3$
3	$\{C, D, E\}$ a $h = 4$	$\{C, D, E\}$ a $h = 5$
4	$\{A, B, C, D, E\}$ a $h = 5$	$\{A, B, C, D, E\}$ a $h = 10$

- ▶ Enlace simple: fusiones a alturas menores (efecto de encadenamiento)
- ▶ Enlace completo: mayor separación entre fusiones



Diámetro de un conglomerado

El diámetro D_G de un grupo G es la mayor disimilitud entre sus miembros:

$$D_G = \max_{\substack{i \in G \\ i' \in G}} d_{ii'}$$

Enlace simple:


Puede producir clusters con diámetros **muy grandes** (encadenamiento).

Enlace completo:

Tiende a producir clusters con diámetros **pequeños** (compactos).



Aglomerativo paso a paso (visual)



Agrupamiento divisivo (top-down)

1. Comenzar con todos los datos en un solo cluster G



Agrupamiento divisivo (top-down)

1. Comenzar con todos los datos en un solo cluster G
2. Encontrar la observación con mayor disimilitud promedio a las demás; moverla a un nuevo cluster H



Agrupamiento divisivo (top-down)

1. Comenzar con todos los datos en un solo cluster G
2. Encontrar la observación con mayor disimilitud promedio a las demás; moverla a un nuevo cluster H
3. Transferir a H las observaciones más cercanas (en promedio) a H que a G



Agrupamiento divisivo (top-down)

1. Comenzar con todos los datos en un solo cluster G
2. Encontrar la observación con mayor disimilitud promedio a las demás; moverla a un nuevo cluster H
3. Transferir a H las observaciones más cercanas (en promedio) a H que a G
4. Elegir qué cluster dividir a continuación (mayor diámetro)



Agrupamiento divisivo (top-down)

1. Comenzar con todos los datos en un solo cluster G
2. Encontrar la observación con mayor disimilitud promedio a las demás; moverla a un nuevo cluster H
3. Transferir a H las observaciones más cercanas (en promedio) a H que a G
4. Elegir qué cluster dividir a continuación (mayor diámetro)
5. Repetir hasta que todos sean singletons



Agrupamiento divisivo (top-down)

1. Comenzar con todos los datos en un solo cluster G
2. Encontrar la observación con mayor disimilitud promedio a las demás; moverla a un nuevo cluster H
3. Transferir a H las observaciones más cercanas (en promedio) a H que a G
4. Elegir qué cluster dividir a continuación (mayor diámetro)
5. Repetir hasta que todos sean singletons

Ventaja: más preciso cuando se buscan pocos clusters grandes.

Desventaja: menos estudiado; decisiones de división irreversibles.



Entrada: Matriz de disimilitudes $\{d_{ii'}\}$

Salida : Dendrograma de divisiones

```

1  $\mathcal{C} \leftarrow \{\{x_1, \dots, x_N\}\}$ 
2 while algún cluster tenga más de 1 elemento do
3   Elegir  $G \in \mathcal{C}$  con mayor diámetro  $D_G$ 
4    $i^* \leftarrow \arg \max_{i \in G} \frac{1}{|G|-1} \sum_{i' \in G, i' \neq i} d_{ii'}$ 
5    $H \leftarrow \{x_{i^*}\}; G \leftarrow G \setminus \{x_{i^*}\}$ 
6   repeat
7     for  $i \in G$  do
8       if  $\bar{d}(i, H) < \bar{d}(i, G \setminus \{i\})$  then
9          $H \leftarrow H \cup \{i\}; G \leftarrow G \setminus \{i\}$ 
10      end
11    end
12    until no haya más transferencias
13     $\mathcal{C} \leftarrow (\mathcal{C} \setminus \{G_{\text{old}}\}) \cup \{G, H\}$ 
14 end

```



Aglomerativo vs. divisivo

Aspecto	Aglomerativo	Divisivo
Dirección	Bottom-up	Top-down
Inicio	N singletons	1 cluster global
Ventaja	Más estudiado	Mejor para pocos clusters
Decisión	Fusionar 2 clusters	Dividir 1 cluster
Complejidad	$O(N^2 \log N)$	$O(2^N)$ (óptimo); $O(N^2)$ heurístico



Caso real: Microarreglos de tumores humanos

Datos: 6830 genes × 64 muestras.

- ▶ Enlace promedio y completo: resultados **similares**



Caso real: Microarreglos de tumores humanos

Datos: 6830 genes × 64 muestras.

- ▶ Enlace promedio y completo: resultados **similares**
- ▶ Enlace simple: grupos desbalanceados, encadenamiento



Caso real: Microarreglos de tumores humanos

Datos: 6830 genes \times 64 muestras.

- ▶ Enlace promedio y completo: resultados **similares**
- ▶ Enlace simple: grupos desbalanceados, encadenamiento
- ▶ Cortar el dendrograma a distintas alturas \rightarrow diferentes K



Caso real: Microarreglos de tumores humanos

Datos: 6830 genes \times 64 muestras.


- ▶ Enlace promedio y completo: resultados **similares**
- ▶ Enlace simple: grupos desbalanceados, encadenamiento
- ▶ Cortar el dendrograma a distintas alturas \rightarrow diferentes K

Ventajas sobre K-means en este caso:

- ▶ Estructura **anidada** (subtipos dentro de tipos)
- ▶ **Ordenamiento** de muestras en el dendrograma
- ▶ Los biólogos pueden interpretar clusters de genes



Heatmap con dendrograma bidireccional



El reordenamiento bidireccional:

- ▶ Filas (genes) y columnas (muestras) reordenadas por dendrograma
- ▶ Revela **patrones** de co-expresión
- ▶ Más informativo que un ordenamiento aleatorio



Agrupamiento jerárquico vs. K-means


Aspecto	Jerárquico	K-means
Requiere K	No	Sí
Resultado	Dendrograma	Partición plana
Anidamiento	Sí	No
Determinístico	Sí	No (dep. de inicio)
Complejidad	$O(N^2 \log N)$	$O(NKpl)$
Escalabilidad	Limitada (N^2)	Buena
Distancia	Cualquiera	Euclíadiana




Orientación de ramas en el dendrograma

Al invertir las ramas de cualquier fusión, el dendrograma sigue siendo válido.

Orden A




Orden B



Orientación de ramas en el dendrograma

Al invertir las ramas de cualquier fusión, el dendrograma sigue siendo válido.


- ▶ Para N fusiones: 2^{N-1} ordenamientos de hojas posibles



Orientación de ramas en el dendrograma

Al invertir las ramas de cualquier fusión, el dendrograma sigue siendo válido.


- ▶ Para N fusiones: 2^{N-1} ordenamientos de hojas posibles
 - ▶ Se añade una **regla de ordenamiento** (ej.: subárbol más compacto a la izquierda)



Orientación de ramas en el dendrograma

Al invertir las ramas de cualquier fusión, el dendrograma sigue siendo válido.

- ▶ Para N fusiones: 2^{N-1} ordenamientos de hojas posibles
- ▶ Se añade una **regla de ordenamiento** (ej.: subárbol más compacto a la izquierda)
- ▶ Alternativa: MDS para ordenar las hojas



Consejos prácticos

1. Elegir el enlace:

- ▶ Enlace promedio o Ward para la mayoría de casos
- ▶ Evitar enlace simple si se sospecha encadenamiento



Consejos prácticos

1. Elegir el enlace:

- ▶ Enlace promedio o Ward para la mayoría de casos
- ▶ Evitar enlace simple si se sospecha encadenamiento

2. Estandarizar variables si tienen escalas diferentes



Consejos prácticos

1. Elegir el enlace:

- ▶ Enlace promedio o Ward para la mayoría de casos
- ▶ Evitar enlace simple si se sospecha encadenamiento

2. Estandarizar variables si tienen escalas diferentes

3. Evaluar calidad: silueta



Consejos prácticos

1. Elegir el enlace:

- ▶ Enlace promedio o Ward para la mayoría de casos
- ▶ Evitar enlace simple si se sospecha encadenamiento

2. Estandarizar variables si tienen escalas diferentes

3. Evaluar calidad: silueta

4. Cortar el dendrograma:

- ▶ Buscar saltos grandes en las alturas de fusión



Consejos prácticos

1. Elegir el enlace:

- ▶ Enlace promedio o Ward para la mayoría de casos
- ▶ Evitar enlace simple si se sospecha encadenamiento

2. Estandarizar variables si tienen escalas diferentes

3. Evaluar calidad: silueta


4. Cortar el dendrograma:

- ▶ Buscar saltos grandes en las alturas de fusión

5. Combinar métodos: jerárquico para explorar estructura, luego K-means para particionar



Pipeline de agrupamiento jerárquico



Conclusiones

Resumen y reflexiones Próximos pasos



Resumen: Agrupamiento jerárquico

1. No requiere fijar K : el dendrograma muestra toda la jerarquía



Resumen: Agrupamiento jerárquico

1. No requiere fijar K : el dendrograma muestra toda la jerarquía
2. Aglomerativo: bottom-up, fusiona los 2 clusters más cercanos



Resumen: Agrupamiento jerárquico

1. No requiere fijar K : el dendrograma muestra toda la jerarquía
2. Aglomerativo: bottom-up, fusiona los 2 clusters más cercanos
3. Divisivo: top-down, divide el cluster más heterogéneo



Resumen: Agrupamiento jerárquico

1. No requiere fijar K : el dendrograma muestra toda la jerarquía
2. Aglomerativo: bottom-up, fusiona los 2 clusters más cercanos
3. Divisivo: top-down, divide el cluster más heterogéneo
4. Enlace: simple, completo, promedio, Ward



Resumen: Agrupamiento jerárquico

1. No requiere fijar K : el dendrograma muestra toda la jerarquía
2. Aglomerativo: bottom-up, fusiona los 2 clusters más cercanos
3. Divisivo: top-down, divide el cluster más heterogéneo
4. Enlace: simple, completo, promedio, Ward
5. Dendrograma: representación visual con estructura anidada



Resumen: Agrupamiento jerárquico

1. No requiere fijar K : el dendrograma muestra toda la jerarquía
2. Aglomerativo: bottom-up, fusiona los 2 clusters más cercanos
3. Divisivo: top-down, divide el cluster más heterogéneo
4. Enlace: simple, completo, promedio, Ward
5. Dendrograma: representación visual con estructura anidada
6. Evaluación: coeficiente cophenético, estadístico Gap



Ventajas

- ▶ No requiere K a priori
- ▶ Estructura anidada
- ▶ Dendrograma interpretable
- ▶ Determinístico
- ▶ Funciona con matrices de disimilitud

Desventajas

- ▶ $O(N^2)$ en espacio
- ▶ No escala bien ($N > 10^4$)
- ▶ Fusiones/divisiones irreversibles
- ▶ Sensible a la elección de enlace
- ▶ Impone estructura jerárquica exista o no



Escenario	Recomendación
Explorar estructura sin fijar K	Jerárquico
Datos genómicos / taxonómicos	Jerárquico
$N > 10,000$	K-means / Mini-batch
Clusters esféricos, N grande	K-means
Clusters no convexos	DBSCAN
Solo matrices de proximidad	Jerárquico o K-medoides



- ▶ Hastie, Tibshirani & Friedman (2009). *The Elements of Statistical Learning*, Cap. 14.





UTEC Posgrado



UTEC Posgrado