



UTEC Posgrado



UTEC Posgrado


MACHINE LEARNING

ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)



Motivación

Contexto y necesidad de la reducción de dimensionalidad



El problema de la alta dimensionalidad

En Machine Learning trabajamos con datos de **alta dimensionalidad**:

- ▶ Imágenes: 100×100 píxeles $\Rightarrow D = 10,000$ dimensiones



El problema de la alta dimensionalidad

En Machine Learning trabajamos con datos de **alta dimensionalidad**:

- ▶ Imágenes: 100×100 píxeles $\Rightarrow D = 10,000$ dimensiones
- ▶ Genómica: $\sim 20,000$ genes medidos simultáneamente



El problema de la alta dimensionalidad

En Machine Learning trabajamos con datos de **alta dimensionalidad**:

- ▶ Imágenes: 100×100 píxeles $\Rightarrow D = 10,000$ dimensiones
- ▶ Genómica: $\sim 20,000$ genes medidos simultáneamente
- ▶ Procesamiento de lenguaje: vocabularios de 10,000+ palabras



El problema de la alta dimensionalidad

En Machine Learning trabajamos con datos de **alta dimensionalidad**:

- ▶ Imágenes: 100×100 píxeles $\Rightarrow D = 10,000$ dimensiones
- ▶ Genómica: $\sim 20,000$ genes medidos simultáneamente
- ▶ Procesamiento de lenguaje: vocabularios de $10,000+$ palabras
- ▶ Sensores IoT: cientos de mediciones por segundo



El problema de la alta dimensionalidad

En Machine Learning trabajamos con datos de **alta dimensionalidad**:

- ▶ Imágenes: 100×100 píxeles $\Rightarrow D = 10,000$ dimensiones
- ▶ Genómica: $\sim 20,000$ genes medidos simultáneamente
- ▶ Procesamiento de lenguaje: vocabularios de $10,000+$ palabras
- ▶ Sensores IoT: cientos de mediciones por segundo

Problema: La *maldición de la dimensionalidad*

- ▶ Distancias pierden significado
- ▶ Necesidad exponencial de datos
- ▶ Alto costo computacional



PCA (Principal Component Analysis) o *Análisis de Componentes Principales*:

- ▶ Técnica de **reducción de dimensionalidad**



PCA (Principal Component Analysis) o *Análisis de Componentes Principales*:

- ▶ Técnica de **reducción de dimensionalidad**
- ▶ Encuentra un subespacio de **menor dimensión** $M < D$



PCA (Principal Component Analysis) o *Análisis de Componentes Principales*:

- ▶ Técnica de **reducción de dimensionalidad**
- ▶ Encuentra un subespacio de **menor dimensión** $M < D$
- ▶ Proyecta los datos en ese subespacio



PCA (Principal Component Analysis) o *Análisis de Componentes Principales*:

- ▶ Técnica de **reducción de dimensionalidad**
- ▶ Encuentra un subespacio de **menor dimensión** $M < D$
- ▶ Proyecta los datos en ese subespacio
- ▶ **Maximiza la varianza** de los datos proyectados



PCA (Principal Component Analysis) o *Análisis de Componentes Principales*:

- ▶ Técnica de **reducción de dimensionalidad**
- ▶ Encuentra un subespacio de **menor dimensión** $M < D$
- ▶ Proyecta los datos en ese subespacio
- ▶ **Maximiza la varianza** de los datos proyectados
- ▶ Equivalentemente: **minimiza el error** de reconstrucción




PCA (Principal Component Analysis) o *Análisis de Componentes Principales*:

- ▶ Técnica de **reducción de dimensionalidad**
 - ▶ Encuentra un subespacio de **menor dimensión** $M < D$
 - ▶ Proyecta los datos en ese subespacio
 - ▶ **Maximiza la varianza** de los datos proyectados
 - ▶ Equivalentemente: **minimiza el error** de reconstrucción
- ▶ Es una transformación **lineal** y **ortogonal**




Intuición geométrica de PCA



- PC1: dirección de **máxima varianza**



Intuición geométrica de PCA



- ▶ PC1: dirección de **máxima varianza**
- ▶ Las proyecciones sobre PC1 capturan la mayor información




Área	Aplicación
Compresión de datos	Reducir tamaño de imágenes, videos
Visualización	Proyectar datos de D dimensiones a 2D/3D
Preprocesamiento	Eliminar correlaciones, reducir ruido
Extracción de características	Reducir features para clasificación
Reconocimiento facial	Eigenfaces (Turk & Pentland, 1991)
Bioinformática	Análisis de expresión génica



Conceptos fundamentales y algoritmo de PCA

Conceptos fundamentales y algoritmo de PCA



Concepto 1: Media muestral

(1) Concepto:

La **media muestral** $\bar{\mathbf{x}}$ es el centro de masa de los datos. Es el punto promedio en el espacio de características.

(2) Fórmula:

Para un conjunto de datos $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ con $\mathbf{x}_n \in \mathbb{R}^D$:

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$$

donde N es el número de observaciones y D es la dimensionalidad.



Concepto 1: Media muestral (ejemplo)

(3) Dataset ejemplo:

Consideremos $N = 4$ puntos en $D = 2$ dimensiones:

Observación	x_1	x_2
\mathbf{x}_1	1	2
\mathbf{x}_2	3	4
\mathbf{x}_3	3	6
\mathbf{x}_4	5	8

(4) Cálculo paso a paso:

$$\bar{x}_1 = \frac{1}{4}(1 + 3 + 3 + 5) = \frac{12}{4} = 3$$

$$\bar{x}_2 = \frac{1}{4}(2 + 4 + 6 + 8) = \frac{20}{4} = 5$$



Antes de aplicar PCA, **centramos** los datos restando la media:

$$\tilde{\mathbf{x}}_n = \mathbf{x}_n - \bar{\mathbf{x}}$$

Para nuestro ejemplo:

n	\mathbf{x}_n	—	$\bar{\mathbf{x}}$	$= \tilde{\mathbf{x}}_n$
1	$\begin{pmatrix} 1 \\ 2 \end{pmatrix}$	—	$\begin{pmatrix} 3 \\ 5 \end{pmatrix}$	$= \begin{pmatrix} -2 \\ -3 \end{pmatrix}$
2	$\begin{pmatrix} 3 \\ 4 \end{pmatrix}$	—	$\begin{pmatrix} 3 \\ 5 \end{pmatrix}$	$= \begin{pmatrix} 0 \\ -1 \end{pmatrix}$
3	$\begin{pmatrix} 3 \\ 6 \end{pmatrix}$	—	$\begin{pmatrix} 3 \\ 5 \end{pmatrix}$	$= \begin{pmatrix} 0 \\ 1 \end{pmatrix}$
4	$\begin{pmatrix} 5 \\ 2 \end{pmatrix}$	—	$\begin{pmatrix} 3 \\ 5 \end{pmatrix}$	$= \begin{pmatrix} 2 \\ -3 \end{pmatrix}$



Concepto 2: Matriz de covarianza

(1) Concepto:

La **matriz de covarianza** **S** mide cómo varían conjuntamente las diferentes dimensiones de los datos.

(2) Fórmula:

Para datos centrados $\tilde{\mathbf{x}}_n$:

$$\mathbf{S} = \frac{1}{N} \sum_{n=1}^N \tilde{\mathbf{x}}_n \tilde{\mathbf{x}}_n^T = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^T$$

S es una matriz simétrica de $D \times D$ donde:

- ▶ Diagonal: varianzas de cada dimensión
- ▶ Fuera de diagonal: covarianzas entre dimensiones



Concepto 2: Matriz de covarianza (ejemplo)

(3) **Dataset:** usamos los datos centrados anteriores

(4) **Cálculo paso a paso:**

$$\begin{aligned}
 \mathbf{S} &= \frac{1}{4} \sum_{n=1}^4 \tilde{\mathbf{x}}_n \tilde{\mathbf{x}}_n^T \\
 &= \frac{1}{4} \left[\begin{pmatrix} -2 \\ -3 \end{pmatrix} \begin{pmatrix} -2 & -3 \end{pmatrix} + \begin{pmatrix} 0 \\ -1 \end{pmatrix} \begin{pmatrix} 0 & -1 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \end{pmatrix} + \begin{pmatrix} 2 \\ 3 \end{pmatrix} \begin{pmatrix} 2 & 3 \end{pmatrix} \right] \\
 &= \frac{1}{4} \left[\begin{pmatrix} 4 & 6 \\ 6 & 9 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 4 & 6 \\ 6 & 9 \end{pmatrix} \right] \\
 &= \frac{1}{4} \begin{pmatrix} 8 & 12 \\ 12 & 20 \end{pmatrix} = \begin{pmatrix} 2 & 3 \\ 3 & 5 \end{pmatrix}
 \end{aligned}$$



Concepto 3: Eigenvectores y eigenvalores

(1) Concepto:

Para una matriz **A**, un **eigenvector** **v** es un vector que al ser multiplicado por **A** solo cambia de escala:

(2) Fórmula:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es el **eigenvalor** asociado.



Concepto 3: Eigenvectores y eigenvalores

(1) Concepto:

Para una matriz **A**, un **eigenvector** **v** es un vector que al ser multiplicado por **A** solo cambia de escala:

(2) Fórmula:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es el **eigenvalor** asociado.

► Para hallar eigenvalores: $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$



Concepto 3: Eigenvectores y eigenvalores

(1) Concepto:

Para una matriz **A**, un **eigenvector** **v** es un vector que al ser multiplicado por **A** solo cambia de escala:

(2) Fórmula:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es el **eigenvalor** asociado.

- ▶ Para hallar eigenvalores: $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$
- ▶ Para hallar eigenvectores: $(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}$



Concepto 3: Eigenvectores y eigenvalores

(1) Concepto:

Para una matriz **A**, un **eigenvector** **v** es un vector que al ser multiplicado por **A** solo cambia de escala:

(2) Fórmula:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es el **eigenvalor** asociado.

- ▶ Para hallar eigenvalores: $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$
- ▶ Para hallar eigenvectores: $(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}$
- ▶ Los eigenvectores de **S** son **ortogonales** (porque **S** es simétrica)



Concepto 3: Eigenvectores y eigenvalores

(1) Concepto:

Para una matriz **A**, un **eigenvector** **v** es un vector que al ser multiplicado por **A** solo cambia de escala:

(2) Fórmula:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es el **eigenvalor** asociado.

- ▶ Para hallar eigenvalores: $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$
- ▶ Para hallar eigenvectores: $(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}$
- ▶ Los eigenvectores de **S** son **ortogonales** (porque **S** es simétrica)
- ▶ Los eigenvalores de **S** indican la **varianza** en la dirección del eigenvector



Concepto 3: Eigenvectores (ejemplo paso 1)

(3) Dataset: $\mathbf{S} = \begin{pmatrix} 2 & 3 \\ 3 & 5 \end{pmatrix}$

(4) Cálculo de eigenvalores:

$$\det(\mathbf{S} - \lambda \mathbf{I}) = 0$$

$$\det \begin{pmatrix} 2 - \lambda & 3 \\ 3 & 5 - \lambda \end{pmatrix} = 0$$

$$(2 - \lambda)(5 - \lambda) - 9 = 0$$

$$\lambda^2 - 7\lambda + 1 = 0$$

Fórmula cuadrática:

$$\lambda = \frac{7 \pm \sqrt{49 - 4}}{2} = \frac{7 \pm \sqrt{45}}{2} = \frac{7 \pm 6,708}{2}$$

$$\Rightarrow \lambda_1 = 6,854 \quad \text{y} \quad \lambda_2 = 0,146$$



Concepto 3: Eigenvectores (ejemplo paso 2)

Para $\lambda_1 = 6,854$:

$$(\mathbf{S} - 6,854\mathbf{I})\mathbf{v}_1 = \mathbf{0}$$

$$\begin{pmatrix} -4,854 & 3 \\ 3 & -1,854 \end{pmatrix} \begin{pmatrix} v_{11} \\ v_{12} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

De la primera ecuación: $-4,854v_{11} + 3v_{12} = 0 \Rightarrow v_{12} = 1,618v_{11}$

Normalizando ($\|\mathbf{v}_1\| = 1$): $\mathbf{v}_1 = \begin{pmatrix} 0,526 \\ 0,850 \end{pmatrix}$

Para $\lambda_2 = 0,146$: $\mathbf{v}_2 = \begin{pmatrix} 0,850 \\ -0,526 \end{pmatrix}$

Nota: $\mathbf{v}_1^T \mathbf{v}_2 = 0$ (ortogonales)



Concepto 4: Proyección

(1) Concepto:

La **proyección** de un punto \mathbf{x} sobre un vector unitario \mathbf{u} es:

(2) Fórmula:

$$z = \mathbf{u}^T \mathbf{x}$$

Esta es la **coordenada** del punto en la dirección \mathbf{u} .

La reconstrucción desde la proyección es:

$$\tilde{\mathbf{x}} = z\mathbf{u} = (\mathbf{u}^T \mathbf{x})\mathbf{u}$$

Para proyectar sobre M componentes principales $\{\mathbf{u}_1, \dots, \mathbf{u}_M\}$:

$$\mathbf{z} = \mathbf{U}^T \mathbf{x}, \quad \text{donde } \mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_M]$$



Concepto 4: Proyección (ejemplo)

(3) **Dataset:** Proyectemos $\tilde{\mathbf{x}}_1 = \begin{pmatrix} -2 \\ -3 \end{pmatrix}$ sobre PC1

(4) **Cálculo:**

Usando $\mathbf{u}_1 = \begin{pmatrix} 0,526 \\ 0,850 \end{pmatrix}$:

$$\begin{aligned} z_1 &= \mathbf{u}_1^T \tilde{\mathbf{x}}_1 \\ &= (0,526 \quad 0,850) \begin{pmatrix} -2 \\ -3 \end{pmatrix} \\ &= (0,526)(-2) + (0,850)(-3) \\ &= -1,052 - 2,550 = -3,602 \end{aligned}$$

Si proyectamos todos los puntos sobre PC1:



Formulación de máxima varianza

Objetivo: Encontrar la dirección \mathbf{u}_1 que maximiza la varianza de los datos proyectados.

La varianza de los datos proyectados es:

$$\text{Var}(z) = \frac{1}{N} \sum_{n=1}^N (\mathbf{u}_1^T \tilde{\mathbf{x}}_n)^2 = \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$$

Maximizar con restricción $\mathbf{u}_1^T \mathbf{u}_1 = 1$:

$$\max_{\mathbf{u}_1} \left\{ \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 + \lambda (1 - \mathbf{u}_1^T \mathbf{u}_1) \right\}$$

Derivando e igualando a cero:

$$\mathbf{S} \mathbf{u}_1 = \lambda \mathbf{u}_1$$

$\Rightarrow \mathbf{u}_1$ es el eigenvector con el mayor eigenvalor!



Formulación de error mínimo

Perspectiva alternativa: PCA minimiza el error de reconstrucción.

Error cuadrático promedio donde $\tilde{\tilde{\mathbf{x}}}_n$ es la reconstrucción:

$$J = \frac{1}{N} \sum_{n=1}^N \|\tilde{\mathbf{x}}_n - \tilde{\tilde{\mathbf{x}}}_n\|^2$$

Se puede demostrar que:

$$J = \sum_{i=M+1}^D \lambda_i$$

⇒ Minimizar J requiere descartar los eigenvectores con menores eigenvalores!

Ambas formulaciones conducen al **mismo resultado**.



Algoritmo de PCA

Entrada: Datos $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, dimensión objetivo M

Salida : Componentes principales \mathbf{U} , datos proyectados \mathbf{Z}

- 1 Calcular la media: $\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$
 - 2 Centrar los datos: $\tilde{\mathbf{x}}_n = \mathbf{x}_n - \bar{\mathbf{x}}$ para $n = 1, \dots, N$
 - 3 Calcular la matriz de covarianza: $\mathbf{S} = \frac{1}{N} \sum_{n=1}^N \tilde{\mathbf{x}}_n \tilde{\mathbf{x}}_n^T$
 - 4 Calcular eigenvalores $\{\lambda_1, \dots, \lambda_D\}$ y eigenvectores $\{\mathbf{v}_1, \dots, \mathbf{v}_D\}$ de \mathbf{S}
 - 5 Ordenar eigenvalores en orden decreciente: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$
 - 6 Seleccionar los M eigenvectores correspondientes a los M mayores eigenvalores
 - 7 Formar matriz $\mathbf{U} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_M]$
 - 8 Proyectar datos: $\mathbf{z}_n = \mathbf{U}^T \tilde{\mathbf{x}}_n$ para $n = 1, \dots, N$
 - 9 **return** \mathbf{U} , $\{\mathbf{z}_1, \dots, \mathbf{z}_N\}$
-



Ejemplo completo: Resumen

Retomemos nuestro ejemplo con $N = 4$ puntos en $D = 2$ dimensiones.

Paso 1: Media

$$\bar{\mathbf{x}} = \begin{pmatrix} 3 \\ 5 \end{pmatrix}$$

Paso 2: Datos centrados

$$\tilde{\mathbf{X}} = \begin{pmatrix} -2 & 0 & 0 & 2 \\ -3 & -1 & 1 & 3 \end{pmatrix}^T$$

Paso 3: Covarianza

$$\mathbf{S} = \begin{pmatrix} 2 & 3 \\ 3 & 5 \end{pmatrix}$$



Ejemplo completo: Componentes principales

Paso 4-6: Eigenvalores y eigenvectores

$$\lambda_1 = 6,854, \quad \mathbf{u}_1 = \begin{pmatrix} 0,526 \\ 0,850 \end{pmatrix}$$

$$\lambda_2 = 0,146, \quad \mathbf{u}_2 = \begin{pmatrix} 0,850 \\ -0,526 \end{pmatrix}$$

Interpretación:

- ▶ PC1 captura $\frac{6,854}{6,854+0,146} = 97,9\%$ de la varianza
- ▶ PC2 captura solo 2,1 % de la varianza

Si reducimos a $M = 1$: proyectamos solo sobre \mathbf{u}_1 , reteniendo 97,9 % de la información!



Ejemplo completo: Proyección y reconstrucción


Para reducir a $M = 1$, proyectamos sobre \mathbf{u}_1 :

n	$\tilde{\mathbf{x}}_n$	$z_n = \mathbf{u}_1^T \tilde{\mathbf{x}}_n$	Reconstrucción $z_n \mathbf{u}_1$
1	$(-2, -3)^T$	-3,602	$(-1,89, -3,06)^T$
2	$(0, -1)^T$	-0,850	$(-0,45, -0,72)^T$
3	$(0, 1)^T$	0,850	$(0,45, 0,72)^T$
4	$(2, 3)^T$	3,602	$(1,89, 3,06)^T$

Dimensionalidad reducida:

- ▶ Original: 4 puntos \times 2 dimensiones = 8 números
- ▶ Comprimido: 4 puntos \times 1 dimensión + \mathbf{u}_1 (2 valores) + $\bar{\mathbf{x}}$ (2 valores) = 8 números
- ▶ Para N grande: ahorro significativo!





¿Cómo elegir M ?

La **proporción de varianza explicada** por los primeros M componentes:

$$\text{PVE}(M) = \frac{\sum_{i=1}^M \lambda_i}{\sum_{i=1}^D \lambda_i}$$

Criterios comunes:

- ▶ Retener componentes hasta alcanzar 90 %, 95 % o 99 % de varianza
- ▶ Regla del codo: donde la curva de varianza acumulada se “aplana”
- ▶ Eigenvalores > 1 (regla de Kaiser)

En nuestro ejemplo:

- ▶ $M = 1$: PVE = 97,9 % ✓ Excelente!
- ▶ $M = 2$: PVE = 100 % (sin reducción)



Propiedades importantes de PCA

1. **Decorrelación:** Los componentes principales están **no correlacionados**

$$\text{Cov}(z_i, z_j) = 0 \quad \text{para } i \neq j$$



Propiedades importantes de PCA

1. **Decorrelación:** Los componentes principales están **no correlacionados**

$$\text{Cov}(z_i, z_j) = 0 \quad \text{para } i \neq j$$

2. **Varianza ordenada:**

$$\text{Var}(z_1) \geq \text{Var}(z_2) \geq \cdots \geq \text{Var}(z_D)$$



Propiedades importantes de PCA

1. **Decorrelación:** Los componentes principales están **no correlacionados**

$$\text{Cov}(z_i, z_j) = 0 \quad \text{para } i \neq j$$

2. **Varianza ordenada:**

$$\text{Var}(z_1) \geq \text{Var}(z_2) \geq \cdots \geq \text{Var}(z_D)$$

3. **Ortogonalidad:** Los eigenvectores son ortogonales

$$\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$$



Propiedades importantes de PCA

1. **Decorrelación:** Los componentes principales están **no correlacionados**

$$\text{Cov}(z_i, z_j) = 0 \quad \text{para } i \neq j$$

2. **Varianza ordenada:**

$$\text{Var}(z_1) \geq \text{Var}(z_2) \geq \dots \geq \text{Var}(z_D)$$

3. **Ortogonalidad:** Los eigenvectores son ortogonales

$$\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$$

4. **Optimalidad:** PCA es óptimo bajo ambas formulaciones (máxima varianza y mínimo error)



Propiedades importantes de PCA

1. **Decorrelación:** Los componentes principales están **no correlacionados**

$$\text{Cov}(z_i, z_j) = 0 \quad \text{para } i \neq j$$

2. **Varianza ordenada:**

$$\text{Var}(z_1) \geq \text{Var}(z_2) \geq \cdots \geq \text{Var}(z_D)$$

3. **Ortogonalidad:** Los eigenvectores son ortogonales

$$\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$$

4. **Optimalidad:** PCA es óptimo bajo ambas formulaciones (máxima varianza y mínimo error)

5. **Unicidad:** Los eigenvectores son únicos (salvo el signo) si los eigenvalores son distintos



1. **Linealidad:** PCA solo encuentra transformaciones **lineales**

- ▶ No captura relaciones no lineales en los datos
- ▶ Solución: Kernel PCA



1. **Linealidad:** PCA solo encuentra transformaciones **lineales**
 - ▶ No captura relaciones no lineales en los datos
 - ▶ Solución: Kernel PCA
2. **Sensibilidad a escala:** Dimensiones con mayor varianza dominan
 - ▶ Solución: Estandarizar datos antes de PCA



1. **Linealidad:** PCA solo encuentra transformaciones **lineales**
 - ▶ No captura relaciones no lineales en los datos
 - ▶ Solución: Kernel PCA
2. **Sensibilidad a escala:** Dimensiones con mayor varianza dominan
 - ▶ Solución: Estandarizar datos antes de PCA
3. **Interpretabilidad:** Los componentes son combinaciones de todas las variables
 - ▶ Pueden ser difíciles de interpretar



1. **Linealidad:** PCA solo encuentra transformaciones **lineales**
 - ▶ No captura relaciones no lineales en los datos
 - ▶ Solución: Kernel PCA
2. **Sensibilidad a escala:** Dimensiones con mayor varianza dominan
 - ▶ Solución: Estandarizar datos antes de PCA
3. **Interpretabilidad:** Los componentes son combinaciones de todas las variables
 - ▶ Pueden ser difíciles de interpretar
4. **Outliers:** PCA es sensible a valores atípicos
 - ▶ Solución: Robust PCA



1. **Linealidad:** PCA solo encuentra transformaciones **lineales**
 - ▶ No captura relaciones no lineales en los datos
 - ▶ Solución: Kernel PCA
2. **Sensibilidad a escala:** Dimensiones con mayor varianza dominan
 - ▶ Solución: Estandarizar datos antes de PCA
3. **Interpretabilidad:** Los componentes son combinaciones de todas las variables
 - ▶ Pueden ser difíciles de interpretar
4. **Outliers:** PCA es sensible a valores atípicos
 - ▶ Solución: Robust PCA
5. **No supervisado:** No usa información de etiquetas
 - ▶ Puede no ser óptimo para clasificación
 - ▶ Alternativa: Linear Discriminant Analysis (LDA)



Conclusiones

Resumen y reflexiones del **Análisis de Componentes Principales**



Resumen: PCA paso a paso

1. Calcular la media \bar{x} de los datos



Resumen: PCA paso a paso

1. **Calcular la media** \bar{x} de los datos
2. **Centrar** los datos: $\tilde{x}_n = x_n - \bar{x}$



Resumen: PCA paso a paso

1. Calcular la media \bar{x} de los datos
2. Centrar los datos: $\tilde{x}_n = x_n - \bar{x}$
3. Calcular la matriz de covarianza S



Resumen: PCA paso a paso

1. Calcular la media \bar{x} de los datos
2. Centrar los datos: $\tilde{x}_n = x_n - \bar{x}$
3. Calcular la matriz de covarianza S
4. Calcular eigenvectores y eigenvalores de S



Resumen: PCA paso a paso

1. **Calcular la media \bar{x}** de los datos
2. **Centrar** los datos: $\tilde{x}_n = x_n - \bar{x}$
3. **Calcular la matriz de covarianza S**
4. **Calcular eigenvectores y eigenvalores de S**
5. **Ordenar** eigenvalores en orden decreciente



Resumen: PCA paso a paso

1. **Calcular la media \bar{x}** de los datos
2. **Centrar** los datos: $\tilde{x}_n = x_n - \bar{x}$
3. **Calcular la matriz de covarianza S**
4. **Calcular eigenvectores y eigenvalores de S**
5. **Ordenar** eigenvalores en orden decreciente
6. **Seleccionar** los M eigenvectores principales



Resumen: PCA paso a paso

1. **Calcular la media** $\bar{\mathbf{x}}$ de los datos
2. **Centrar** los datos: $\tilde{\mathbf{x}}_n = \mathbf{x}_n - \bar{\mathbf{x}}$
3. **Calcular la matriz de covarianza** \mathbf{S}
4. **Calcular eigenvectores y eigenvalores** de \mathbf{S}
5. **Ordenar** eigenvalores en orden decreciente
6. **Seleccionar** los M eigenvectores principales
7. **Proyectar** los datos: $\mathbf{z}_n = \mathbf{U}^T \tilde{\mathbf{x}}_n$



Resumen: PCA paso a paso

1. **Calcular la media** $\bar{\mathbf{x}}$ de los datos
2. **Centrar** los datos: $\tilde{\mathbf{x}}_n = \mathbf{x}_n - \bar{\mathbf{x}}$
3. **Calcular la matriz de covarianza** \mathbf{S}
4. **Calcular eigenvectores y eigenvalores** de \mathbf{S}
5. **Ordenar** eigenvalores en orden decreciente
6. **Seleccionar** los M eigenvectores principales
7. **Proyectar** los datos: $\mathbf{z}_n = \mathbf{U}^T \tilde{\mathbf{x}}_n$

Resultado: Datos de dimensión D reducidos a dimensión M , reteniendo la máxima varianza posible.



Conceptos clave aprendidos

- ▶ **Media muestral:** Centro de los datos



Conceptos clave aprendidos

- ▶ **Media muestral:** Centro de los datos
- ▶ **Matriz de covarianza:** Cómo varían juntas las dimensiones



Conceptos clave aprendidos

- ▶ **Media muestral:** Centro de los datos
- ▶ **Matriz de covarianza:** Cómo varían juntas las dimensiones
- ▶ **Eigenvectores:** Direcciones principales de varianza



Conceptos clave aprendidos

- ▶ **Media muestral:** Centro de los datos
- ▶ **Matriz de covarianza:** Cómo varían juntas las dimensiones
- ▶ **Eigenvectores:** Direcciones principales de varianza
- ▶ **Eigenvalores:** Magnitud de varianza en cada dirección



Conceptos clave aprendidos

- ▶ **Media muestral:** Centro de los datos
- ▶ **Matriz de covarianza:** Cómo varían juntas las dimensiones
- ▶ **Eigenvectores:** Direcciones principales de varianza
- ▶ **Eigenvalores:** Magnitud de varianza en cada dirección
- ▶ **Proyección:** Transformación a menor dimensión



Conceptos clave aprendidos

- ▶ **Media muestral:** Centro de los datos
- ▶ **Matriz de covarianza:** Cómo varían juntas las dimensiones
- ▶ **Eigenvectores:** Direcciones principales de varianza
- ▶ **Eigenvalores:** Magnitud de varianza en cada dirección
- ▶ **Proyección:** Transformación a menor dimensión
- ▶ **Varianza explicada:** Qué tanto se retiene con M componentes



Conceptos clave aprendidos

- ▶ **Media muestral:** Centro de los datos
- ▶ **Matriz de covarianza:** Cómo varían juntas las dimensiones
- ▶ **Eigenvectores:** Direcciones principales de varianza
- ▶ **Eigenvalores:** Magnitud de varianza en cada dirección
- ▶ **Proyección:** Transformación a menor dimensión
- ▶ **Varianza explicada:** Qué tanto se retiene con M componentes

PCA unifica dos perspectivas:

1. Maximizar varianza proyectada
2. Minimizar error de reconstrucción



¿Cuándo usar PCA?

Escenario	Decisión
Features correlacionadas	✓ Usar PCA
Visualización ($D \gg 3$)	✓ Usar PCA
Compresión de datos	✓ Usar PCA
Preprocesamiento	✓ Considerar PCA
ML	
Relaciones no lineales	✗ Kernel PCA / t-SNE
Problema supervisado	✗ Considerar LDA
Interpretabilidad crítica	✗ Evitar PCA



PCA está disponible en todas las bibliotecas populares de ML:

Python (scikit-learn):

```
from sklearn.decomposition import PCA  
pca = PCA(n_components=2)  
X_reduced = pca.fit_transform(X)
```

R:

```
pca_result <- prcomp(X, scale = TRUE)  
X_reduced <- pca_result$x[, 1:2]
```

MATLAB:

```
[coeff, score, latent] = pca(X);  
X_reduced = score(:, 1:2);
```





UTEC Posgrado

