UTEC Posgrado

UTEC Posgrado

UTEC Posgrado

Una escuela para
Early Adopters

MACHINE LEARNING

SMOTE

Synthetic Minority Over-sampling Technique

Motivación

Contexto y necesidad **del sobremuestreo sintético**

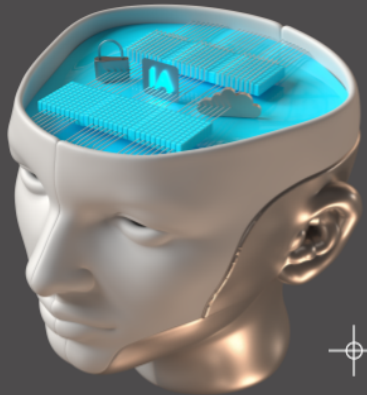

¿Qué es el desbalance de clases?

Un dataset está **desbalanceado** cuando una clase tiene significativamente más observaciones que otra.

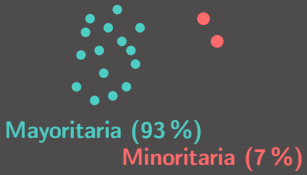

¿Qué es el desbalance de clases?

Un dataset está **desbalanceado** cuando una clase tiene significativamente más observaciones que otra.

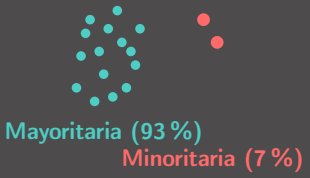

- Fraude bancario: $< 1\,\%$ fraudes

¿Qué es el desbalance de clases?

Un dataset está **desbalanceado** cuando una clase tiene significativamente más observaciones que otra.

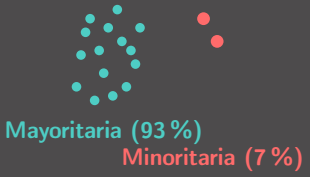

- Fraude bancario: $< 1\,\%$ fraudes
- Diagnóstico médico: enfermedades raras

¿Qué es el desbalance de clases?

Un dataset está **desbalanceado** cuando una clase tiene significativamente más observaciones que otra.

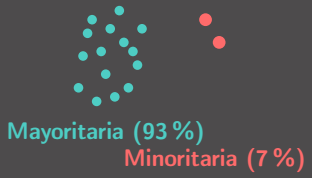

- Fraude bancario: $< 1\,\%$ fraudes
- Diagnóstico médico: enfermedades raras
- Detección de intrusos en redes

¿Qué es el desbalance de clases?

Un dataset está **desbalanceado** cuando una clase tiene significativamente más observaciones que otra.

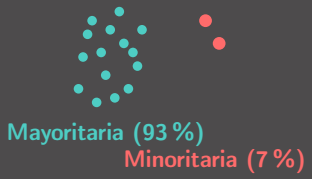

- Fraude bancario: $< 1\,\%$ fraudes
- Diagnóstico médico: enfermedades raras
- Detección de intrusos en redes
- Defectos en manufactura

Problemas del desbalance de clases

Los clasificadores tradicionales **minimizan el error global**, lo que favorece a la clase mayoritaria:

- Un clasificador que **siempre predice la clase mayoritaria** obtiene alta exactitud (accuracy), pero es inútil

Problemas del desbalance de clases

Los clasificadores tradicionales **minimizan el error global**, lo que favorece a la clase mayoritaria:

- Un clasificador que **siempre predice la clase mayoritaria** obtiene alta exactitud (accuracy), pero es inútil
- **Ejemplo:** 98 % clase 0, 2 % clase 1 $\Rightarrow$ predecir siempre 0 da 98 % accuracy

Problemas del desbalance de clases

Los clasificadores tradicionales **minimizan el error global**, lo que favorece a la clase mayoritaria:

- Un clasificador que **siempre predice la clase mayoritaria** obtiene alta exactitud (accuracy), pero es inútil
- **Ejemplo:** 98 % clase 0, 2 % clase 1 $\Rightarrow$ predecir siempre 0 da 98 % accuracy
- La clase minoritaria—generalmente la más **importante**—es ignorada

Problemas del desbalance de clases

Los clasificadores tradicionales **minimizan el error global**, lo que favorece a la clase mayoritaria:

- Un clasificador que **siempre predice la clase mayoritaria** obtiene alta exactitud (accuracy), pero es inútil
- **Ejemplo:** 98 % clase 0, 2 % clase 1 $\Rightarrow$ predecir siempre 0 da 98 % accuracy
- La clase minoritaria—generalmente la más **importante**—es ignorada
- Las fronteras de decisión se sesgan hacia la clase mayoritaria

Problemas del desbalance de clases

Los clasificadores tradicionales **minimizan el error global**, lo que favorece a la clase mayoritaria:

- Un clasificador que **siempre predice la clase mayoritaria** obtiene alta exactitud (accuracy), pero es inútil
- **Ejemplo:** 98 % clase 0, 2 % clase 1 $\Rightarrow$ predecir siempre 0 da 98 % accuracy
- La clase minoritaria—generalmente la más **importante**—es ignorada
- Las fronteras de decisión se sesgan hacia la clase mayoritaria

¿Cómo resolver este problema? $\Longrightarrow$ Técnicas de remuestreo, entre ellas **SMOTE**

Estrategias para manejar el desbalance

Estrategia	Descripción	Ejemplo
Undersampling	Reducir la clase mayoritaria	Random Undersampling
Oversampling	Aumentar la clase minoritaria	Random Oversampling
Oversampling sintético	Generar nuevas muestras artificiales	**SMOTE**
Nivel de algoritmo	Ajustar pesos o umbrales del clasificador	Cost-sensitive learning

¿Por qué no simplemente duplicar muestras?

El **random oversampling** (duplicar) tiene limitaciones:

Duplicar (Random Oversampling):

- Copia exacta de muestras existentes
- Causa sobreajuste (overfitting)
- No añade información nueva
- Frontera de decisión rígida

SMOTE (sintético):

- Crea nuevos puntos **entre** los existentes
- Generaliza mejor
- Añade variabilidad al espacio de características
- Frontera más suave

¿Por qué no simplemente duplicar muestras?

El **random oversampling** (duplicar) tiene limitaciones:

Duplicar (Random Oversampling):

- Copia exacta de muestras existentes
- Causa sobreajuste (overfitting)
- No añade información nueva
- Frontera de decisión rígida

SMOTE (sintético):

- Crea nuevos puntos **entre** los existentes
- Generaliza mejor
- Añade variabilidad al espacio de características
- Frontera más suave

Chawla et al. (2002): "SMOTE causes the classifier to build larger and less specific decision regions"

UTEC Posgrado

Una escuela para
Early Adopters

Desarrollo

SMOTE

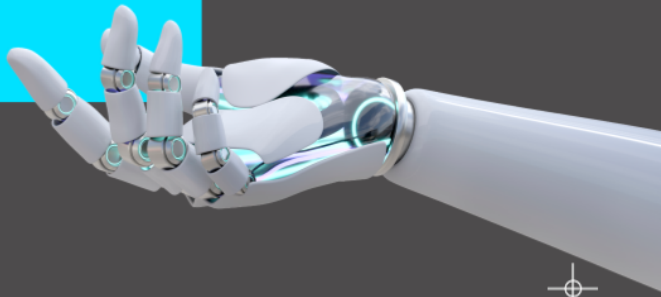

Concepto previo 1: Distancia euclidiana

La **distancia euclidiana** mide la "distancia en línea recta" entre dos puntos en un espacio p-dimensional.

- Es la extensión del teorema de Pitágoras a p dimensiones

Concepto previo 1: Distancia euclidiana

La **distancia euclidiana** mide la "distancia en línea recta" entre dos puntos en un espacio p-dimensional.

- Es la extensión del teorema de Pitágoras a p dimensiones
- Es la métrica más común en aprendizaje automático

Concepto previo 1: Distancia euclidiana

La **distancia euclidiana** mide la "distancia en línea recta" entre dos puntos en un espacio p-dimensional.

- Es la extensión del teorema de Pitágoras a p dimensiones
- Es la métrica más común en aprendizaje automático
- En SMOTE se usa para identificar los **vecinos más cercanos**

Concepto previo 1: Distancia euclidiana

La **distancia euclidiana** mide la "distancia en línea recta" entre dos puntos en un espacio p-dimensional.

- Es la extensión del teorema de Pitágoras a p dimensiones
- Es la métrica más común en aprendizaje automático
- En SMOTE se usa para identificar los **vecinos más cercanos**

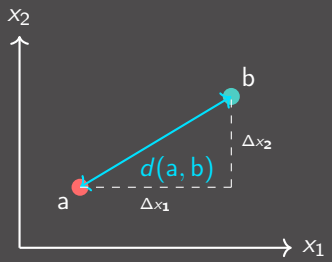

Distancia euclidiana: Fórmula

Dados dos puntos $\mathrm{x}_i = (x_{i1}, x_{i2}, \ldots, x_{ip})$ y $\mathrm{x}_j = (x_{j1}, x_{j2}, \ldots, x_{jp})$:

Distancia euclidiana

$$d(\mathrm{x}_i, \mathrm{x}_j) = \sqrt{\sum_{l=1}^{p} (x_{il} - x_{jl})^2}$$

- Para $p = 2$: $d = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2}$
- Para $p = 1$: $d = |x_{i1} - x_{j1}|$

Distancia euclidiana: Dataset de ejemplo

Consideremos 5 puntos de la **clase minoritaria** en $\mathbb{R}^2$:

Punto	x_1	x_2
A	1	2
B	3	4
C	2	1
D	5	5
E	4	2

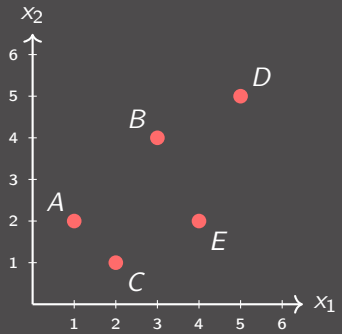

Estos mismos puntos se usarán en todos los ejemplos siguientes.

Distancia euclidiana: Ejemplo paso a paso

Calculemos $d(A, B)$ con $A = (1, 2)$ y $B = (3, 4)$:

$$\begin{aligned} d(A, B) &= \sqrt{(x_{A1} - x_{B1})^2 + (x_{A2} - x_{B2})^2} \\ &= \sqrt{(1-3)^2 + (2-4)^2} \\ &= \sqrt{(-2)^2 + (-2)^2} \\ &= \sqrt{4+4} = \sqrt{8} \approx 2{,}83 \end{aligned}$$

Distancia euclidiana: Matriz completa

Matriz completa de distancias (redondeada a 2 decimales):

	A	B	C	D	E
A	0				
B	2.83	0			
C	1.41	3.16	0		
D	5.00	2.24	5.00	0	
E	3.00	2.24	2.24	3.16	0

Esta matriz será utilizada para determinar los K vecinos más cercanos de cada punto.

Concepto previo 2: K-Vecinos más cercanos

En el contexto de SMOTE, usamos K-NN para encontrar los K puntos **más cercanos** a cada observación de la clase minoritaria.

- No es un modelo de clasificación aquí, sino una **búsqueda de vecindario**

Concepto previo 2: K-Vecinos más cercanos

En el contexto de SMOTE, usamos K-NN para encontrar los K puntos **más cercanos** a cada observación de la clase minoritaria.

- No es un modelo de clasificación aquí, sino una **búsqueda de vecindario**
- Para cada punto minoritario x_i, encontramos sus K vecinos más próximos **dentro de la misma clase minoritaria**

Concepto previo 2: K-Vecinos más cercanos

En el contexto de SMOTE, usamos K-NN para encontrar los K puntos **más cercanos** a cada observación de la clase minoritaria.

- No es un modelo de clasificación aquí, sino una **búsqueda de vecindario**
- Para cada punto minoritario x_i, encontramos sus K vecinos más próximos **dentro de la misma clase minoritaria**
- El parámetro K (típicamente $K = 5$) controla el **tamaño del vecindario**

Concepto previo 2: K-Vecinos más cercanos

En el contexto de SMOTE, usamos K-NN para encontrar los K puntos **más cercanos** a cada observación de la clase minoritaria.

- No es un modelo de clasificación aquí, sino una **búsqueda de vecindario**
- Para cada punto minoritario x_i, encontramos sus K vecinos más próximos **dentro de la misma clase minoritaria**
- El parámetro K (típicamente $K = 5$) controla el **tamaño del vecindario**

▷ A mayor K, los puntos sintéticos se generan desde vecindarios más amplios.

K-Vecinos más cercanos: Procedimiento

Procedimiento para encontrar K-NN de x_i

1. Calcular la distancia $d(x_i, x_j)$ para todo $j \neq i$ en la clase minoritaria
2. Ordenar las distancias de menor a mayor
3. Seleccionar los K puntos con **menor distancia**

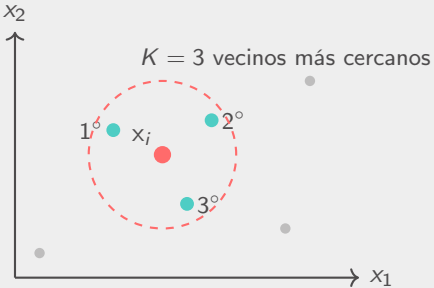

K-NN: Ejemplo paso a paso ($K = 3$)

Encontremos los $K = 3$ vecinos más cercanos de cada punto:

Para el punto $A = (1, 2)$:

Vecino	Distancia	Orden
C	1.41	1° vecino
B	2.83	2° vecino
E	3.00	3° vecino
D	5.00	(fuera del vecindario)

$\Rightarrow$ Los 3-NN de A son: $\{C, B, E\}$

K-NN completos del dataset ($K = 3$)

Punto	Distancias ordenadas	3-NN
$A(1,2)$	C: 1.41, B: 2.83, E: 3.00, D: 5.00	$\{C, B, E\}$
$B(3,4)$	D: 2.24, E: 2.24, A: 2.83, C: 3.16	$\{D, E, A\}$
$C(2,1)$	A: 1.41, E: 2.24, B: 3.16, D: 5.00	$\{A, E, B\}$
$D(5,5)$	B: 2.24, E: 3.16, A: 5.00, C: 5.00	$\{B, E, A\}$
$E(4,2)$	C: 2.24, B: 2.24, A: 3.00, D: 3.16	$\{C, B, A\}$

Concepto previo 3: Interpolación lineal

La **interpolación lineal** genera un punto nuevo **sobre el segmento** que une dos puntos existentes.

- Es la base de la generación sintética en SMOTE

Concepto previo 3: Interpolación lineal

La **interpolación lineal** genera un punto nuevo **sobre el segmento** que une dos puntos existentes.

- Es la base de la generación sintética en SMOTE
- Se controla con un parámetro $\lambda \in [0, 1]$ aleatorio

Concepto previo 3: Interpolación lineal

La **interpolación lineal** genera un punto nuevo **sobre el segmento** que une dos puntos existentes.

- Es la base de la generación sintética en SMOTE
- Se controla con un parámetro $\lambda \in [0, 1]$ aleatorio
- Garantiza que el punto sintético esté **entre** los dos puntos originales

Concepto previo 3: Interpolación lineal

La **interpolación lineal** genera un punto nuevo **sobre el segmento** que une dos puntos existentes.

- Es la base de la generación sintética en SMOTE
- Se controla con un parámetro $\lambda \in [0, 1]$ aleatorio
- Garantiza que el punto sintético esté **entre** los dos puntos originales

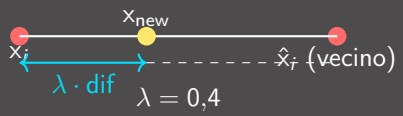

Interpolación lineal: Fórmula

Dados un punto x_i y uno de sus vecinos $\hat{x}_i$:

Fórmula de generación sintética (SMOTE)

$$x_{new} = x_i + \lambda \cdot (\hat{x}_i - x_i)$$

donde $\lambda \sim \text{Uniforme}(0, 1)$ es un número aleatorio.

Componente por componente:

$$x_{\text{new},l} = x_{il} + \lambda \cdot (\hat{x}_{il} - x_{il}), \quad l = 1, \ldots, p$$

- Si $\lambda = 0$: $x_{new} = x_i$ (el punto original)
- Si $\lambda = 1$: $x_{new} = \hat{x}_i$ (el vecino)
- Si $\lambda = 0{,}5$: punto medio exacto

Interpolación lineal: Ejemplo paso a paso

Generemos un punto sintético entre $A = (1, 2)$ y su vecino $C = (2, 1)$ con $\lambda = 0{,}4$:

$$\mathrm{x}_{\text{new}} = \mathrm{x}_A + \lambda \cdot (\mathrm{x}_C - \mathrm{x}_A)$$

$$x_{\text{new},1} = 1 + 0{,}4 \times (2 - 1) = 1 + 0{,}4 \times 1 = 1{,}4$$

$$x_{\text{new},2} = 2 + 0{,}4 \times (1 - 2) = 2 + 0{,}4 \times (-1) = 1{,}6$$

$\Rightarrow$ Punto sintético: $\mathrm{x}_{\text{new}} = (1{,}4, 1{,}6)$

Interpolación lineal: Ejemplo visual

Visualización del punto sintético generado entre $A = (1, 2)$ y $C = (2, 1)$ con $\lambda = 0{,}4$:

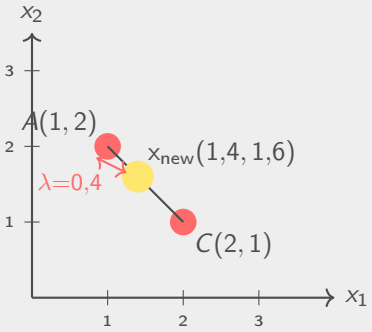

SMOTE: Definición

SMOTE (Synthetic Minority Over-sampling Technique) fue propuesto por **Chawla et al. (2002)**.

Idea central

Generar muestras sintéticas de la clase minoritaria mediante **interpolación lineal** entre cada punto minoritario y sus K vecinos más cercanos (también minoritarios).

Parámetros:

- K: número de vecinos más cercanos (por defecto $K = 5$)
- N: cantidad de sobremuestreo deseado (e.g., 200 % $\Rightarrow$ 2 sintéticos por punto)

Referencia: Chawla, N.V., Bowyer, K.W., Hall, L.O. & Kegelmeyer, W.P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. JAIR, 16, 321–357. [Enlace]

Algoritmo SMOTE

Algoritmo 1: SMOTE — Synthetic Minority Over-sampling Technique

Entrada: Muestras minoritarias $S_{\text{mín}} = \{x_1, \ldots, x_T\}$, parámetros K, N

Salida : Conjunto de muestras sintéticas S_{syn}

```
S_syn ← ∅
for i = 1 to T do
    Calcular los K vecinos más cercanos de x_i en S_mín
    Seleccionar aleatoriamente N vecinos de los K vecinos
    for cada vecino seleccionado x̂_i do
        Generar λ ~ Uniforme(0, 1)
        x_new ← x_i + λ · (x̂_i − x_i)
        S_syn ← S_syn ∪ {x_new}
    end
end
return S_syn
```

SMOTE: Flujo visual

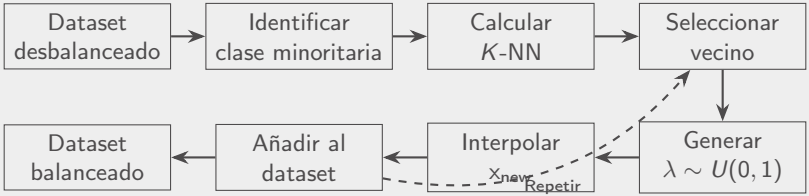

SMOTE: Ejemplo completo — Configuración

Dataset: Nuestros 5 puntos minoritarios con $K = 3$, generar $N = 1$ sintético por punto.

Punto	x_1	x_2
A	1	2
B	3	4
C	2	1
D	5	5
E	4	2

Vecinos ($K = 3$):

Punto	3-NN
A	$\{C, B, E\}$
B	$\{D, E, A\}$
C	$\{A, E, B\}$
D	$\{B, E, A\}$
E	$\{C, B, A\}$

Para cada punto, seleccionamos **1 vecino aleatorio** de sus 3-NN y generamos 1 muestra sintética.

SMOTE: Paso 1 — Sintético desde A

Punto: $A = (1, 2)$. **Vecino aleatorio:** $C = (2, 1)$. $\lambda = 0{,}4$

$$x_{\text{new},1} = 1 + 0{,}4 \times (2 - 1) = 1{,}4$$
$$x_{\text{new},2} = 2 + 0{,}4 \times (1 - 2) = 1{,}6$$

$\Rightarrow$ Sintético $S_1 = (1{,}4, 1{,}6)$

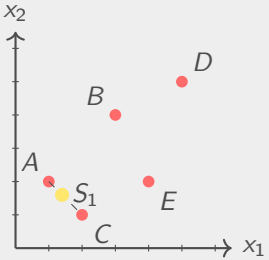

SMOTE: Paso 2 — Sintético desde B

Punto: $B = (3, 4)$. **Vecino aleatorio:** $D = (5, 5)$. $\lambda = 0{,}6$

$$x_{\text{new},1} = 3 + 0{,}6 \times (5 - 3) = 3 + 1{,}2 = 4{,}2$$
$$x_{\text{new},2} = 4 + 0{,}6 \times (5 - 4) = 4 + 0{,}6 = 4{,}6$$

$\Rightarrow$ Sintético $S_2 = (4{,}2, 4{,}6)$

SMOTE: Paso 2 — Visualización

Sintético $S_2 = (4{,}2, 4{,}6)$ generado entre $B = (3, 4)$ y $D = (5, 5)$ con $\lambda = 0{,}6$:

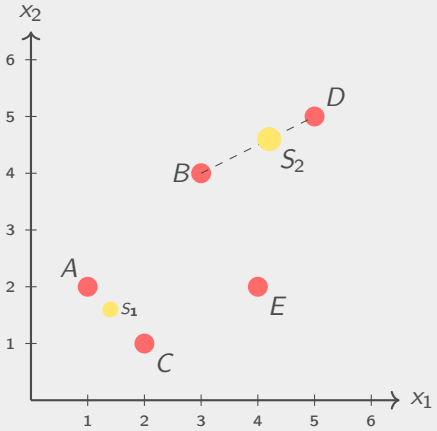

SMOTE: Pasos 3–5 — Resumen

Paso	Punto	Vecino	λ	Cálculo	Sintético
3	$C(2,1)$	$E(4,2)$	0.3	$(2{+}0{,}6,\ 1{+}0{,}3)$	$S_3 = (2{,}6, 1{,}3)$
4	$D(5,5)$	$B(3,4)$	0.7	$(5{-}1{,}4,\ 5{-}0{,}7)$	$S_4 = (3{,}6, 4{,}3)$
5	$E(4,2)$	$C(2,1)$	0.5	$(4{-}1{,}0,\ 2{-}0{,}5)$	$S_5 = (3{,}0, 1{,}5)$

Resultado: De 5 puntos minoritarios $\rightarrow$ 5 sintéticos $\rightarrow$ **10 puntos totales** en la clase minoritaria (100 % oversampling).

SMOTE: Resultado visual

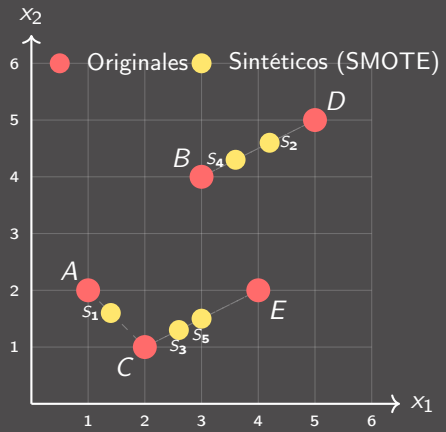

Cada punto sintético yace **sobre el segmento** entre un punto original y uno de sus vecinos.

Antes y después de SMOTE

Antes (desbalanceado):

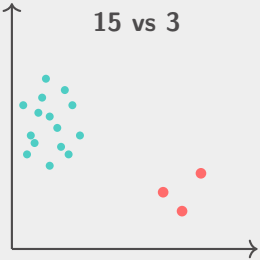

Después (balanceado con SMOTE):

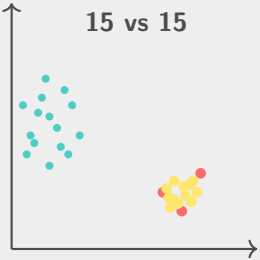

Los sintéticos (●) llenan la región del espacio de la clase minoritaria (●), sin duplicar.

Efecto de SMOTE en la frontera de decisión

Sin SMOTE:

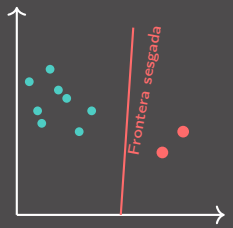

Con SMOTE:

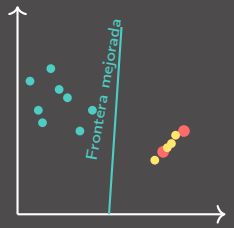

SMOTE expande la región de decisión de la clase minoritaria, produciendo fronteras más generalizables (Chawla et al., 2002).

Parámetros clave de SMOTE

Parámetro	Descripción	Efecto
K	Número de vecinos más cercanos	Mayor $K \rightarrow$ sintéticos más dispersos
N **(o ratio)**	Cantidad de sobremuestreo	Controla cuántos sintéticos se generan
Métrica	Distancia para calcular K-NN	Euclidiana es la más común

Regla práctica:

- $K = 5$ es el valor por defecto más usado
- El ratio de sobremuestreo se elige para **equilibrar** las clases
- Si la clase minoritaria tiene T muestras y la mayoritaria M: generar $M - T$ sintéticos

Efecto del parámetro K en SMOTE

$K = 1$:

$K = 5$:

K pequeño $\rightarrow$ interpolación local; K grande $\rightarrow$ mayor cobertura del espacio.

Variantes de SMOTE

Variante	Descripción
SMOTE original	Interpola entre cada punto minoritario y sus K-NN (Chawla et al., 2002)
Borderline-SMOTE	Solo genera sintéticos desde puntos **cercanos a la frontera** de decisión (Han et al., 2005)
ADASYN	Genera **más sintéticos** donde la densidad de la minoritaria es menor (He et al., 2008)
SMOTE-ENN	Combina SMOTE con Edited Nearest Neighbors para **limpiar** ruido
SMOTE-Tomek	Combina SMOTE con remoción de **Tomek Links**

Limitaciones de SMOTE

1. **Ruido amplificado:** Si un punto minoritario es ruido (outlier), SMOTE genera sintéticos cerca de él, amplificando el error

Limitaciones de SMOTE

1. **Ruido amplificado:** Si un punto minoritario es ruido (outlier), SMOTE genera sintéticos cerca de él, amplificando el error
2. **Solapamiento de clases:** En regiones donde las clases se solapan, los sintéticos pueden caer en la zona de la clase mayoritaria

Limitaciones de SMOTE

1. **Ruido amplificado:** Si un punto minoritario es ruido (outlier), SMOTE genera sintéticos cerca de él, amplificando el error
2. **Solapamiento de clases:** En regiones donde las clases se solapan, los sintéticos pueden caer en la zona de la clase mayoritaria
3. **No considera la clase mayoritaria:** Los K-NN se calculan solo entre minoritarios; no verifica si los sintéticos están en zona "segura"

Limitaciones de SMOTE

1. **Ruido amplificado:** Si un punto minoritario es ruido (outlier), SMOTE genera sintéticos cerca de él, amplificando el error
2. **Solapamiento de clases:** En regiones donde las clases se solapan, los sintéticos pueden caer en la zona de la clase mayoritaria
3. **No considera la clase mayoritaria:** Los K-NN se calculan solo entre minoritarios; no verifica si los sintéticos están en zona "segura"
4. **Variables categóricas:** La interpolación lineal no aplica directamente a datos categóricos (se necesitan extensiones como SMOTE-NC)

Limitaciones de SMOTE

1. **Ruido amplificado:** Si un punto minoritario es ruido (outlier), SMOTE genera sintéticos cerca de él, amplificando el error
2. **Solapamiento de clases:** En regiones donde las clases se solapan, los sintéticos pueden caer en la zona de la clase mayoritaria
3. **No considera la clase mayoritaria:** Los K-NN se calculan solo entre minoritarios; no verifica si los sintéticos están en zona "segura"
4. **Variables categóricas:** La interpolación lineal no aplica directamente a datos categóricos (se necesitan extensiones como SMOTE-NC)
5. **Alta dimensión:** En espacios de alta dimensionalidad, las distancias pierden significado (maldición de la dimensionalidad)

Problema: SMOTE amplifica ruido

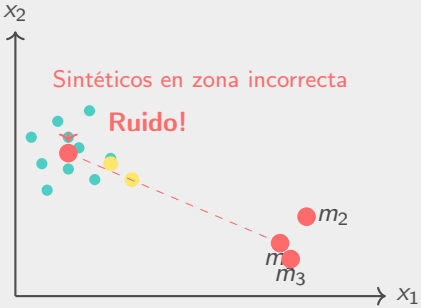

Solución: Usar variantes como Borderline-SMOTE o SMOTE-ENN que filtran ruido.

Buenas prácticas con SMOTE

1. **Aplicar SMOTE solo al conjunto de entrenamiento**
   - Nunca al conjunto de validación ni de prueba
   - Esto evita **data leakage**

Buenas prácticas con SMOTE

1. **Aplicar SMOTE solo al conjunto de entrenamiento**
   - Nunca al conjunto de validación ni de prueba
   - Esto evita **data leakage**
2. **Integrar en un pipeline**
   - SMOTE debe ir **después** del split train/test
   - Usar pipelines de `imbalanced-learn` en Python

Buenas prácticas con SMOTE

1. **Aplicar SMOTE solo al conjunto de entrenamiento**
   - Nunca al conjunto de validación ni de prueba
   - Esto evita **data leakage**
2. **Integrar en un pipeline**
   - SMOTE debe ir **después** del split train/test
   - Usar pipelines de `imbalanced-learn` en Python
3. **Evaluar con métricas apropiadas**
   - No usar accuracy; preferir **F1-score**, **AUC-ROC**, **precision-recall**

Buenas prácticas con SMOTE

1. **Aplicar SMOTE solo al conjunto de entrenamiento**
   - Nunca al conjunto de validación ni de prueba
   - Esto evita **data leakage**
2. **Integrar en un pipeline**
   - SMOTE debe ir **después** del split train/test
   - Usar pipelines de `imbalanced-learn` en Python
3. **Evaluar con métricas apropiadas**
   - No usar accuracy; preferir **F1-score**, **AUC-ROC**, **precision-recall**
4. **Combinar con undersampling**
   - SMOTE + Tomek Links o SMOTE + ENN suelen dar mejores resultados

Buenas prácticas con SMOTE

1. **Aplicar SMOTE solo al conjunto de entrenamiento**
   - Nunca al conjunto de validación ni de prueba
   - Esto evita **data leakage**
2. **Integrar en un pipeline**
   - SMOTE debe ir **después** del split train/test
   - Usar pipelines de `imbalanced-learn` en Python
3. **Evaluar con métricas apropiadas**
   - No usar accuracy; preferir **F1-score**, **AUC-ROC**, **precision-recall**
4. **Combinar con undersampling**
   - SMOTE + Tomek Links o SMOTE + ENN suelen dar mejores resultados
5. **Experimentar con K y el ratio**

Pipeline correcto con SMOTE

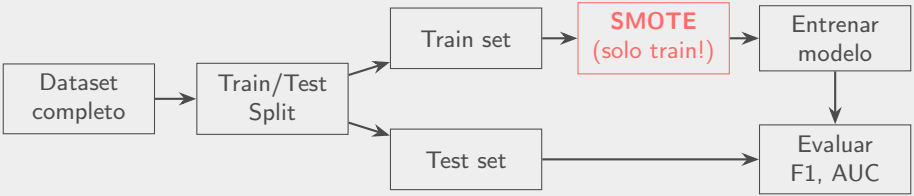

Error común: Aplicar SMOTE **antes** de separar train/test $\Rightarrow$ data leakage.

Los sintéticos del test set contendrían información del train set.

Conclusiones

Resumen y reflexiones **sobre SMOTE**

Resumen: SMOTE

1. **Problema:** El desbalance de clases sesga los clasificadores hacia la clase mayoritaria

Resumen: SMOTE

1. **Problema:** El desbalance de clases sesga los clasificadores hacia la clase mayoritaria
2. **SMOTE:** Genera muestras sintéticas por interpolación lineal entre puntos minoritarios y sus K-NN

Resumen: SMOTE

1. **Problema:** El desbalance de clases sesga los clasificadores hacia la clase mayoritaria
2. **SMOTE:** Genera muestras sintéticas por interpolación lineal entre puntos minoritarios y sus K-NN
3. **Conceptos clave:**
   - Distancia euclidiana para medir proximidad
   - K-NN para identificar vecindarios
   - Interpolación lineal para generar puntos nuevos

Resumen: SMOTE

1. **Problema:** El desbalance de clases sesga los clasificadores hacia la clase mayoritaria
2. **SMOTE:** Genera muestras sintéticas por interpolación lineal entre puntos minoritarios y sus K-NN
3. **Conceptos clave:**
   - Distancia euclidiana para medir proximidad
   - K-NN para identificar vecindarios
   - Interpolación lineal para generar puntos nuevos
4. **Fórmula:** $\mathrm{x}_{\text{new}} = \mathrm{x}_i + \lambda \cdot (\hat{\mathrm{x}}_i - \mathrm{x}_i)$, con $\lambda \sim U(0, 1)$

Resumen: SMOTE

1. **Problema:** El desbalance de clases sesga los clasificadores hacia la clase mayoritaria
2. **SMOTE:** Genera muestras sintéticas por interpolación lineal entre puntos minoritarios y sus K-NN
3. **Conceptos clave:**
   - Distancia euclidiana para medir proximidad
   - K-NN para identificar vecindarios
   - Interpolación lineal para generar puntos nuevos
4. **Fórmula:** $\mathrm{x}_{\text{new}} = \mathrm{x}_i + \lambda \cdot (\hat{\mathrm{x}}_i - \mathrm{x}_i)$, con $\lambda \sim U(0, 1)$
5. **Resultado:** Fronteras de decisión más amplias y menos sobreajuste que duplicar

Ventajas y desventajas de SMOTE

Ventajas

- No duplica: genera puntos **nuevos**
- Reduce sobreajuste vs. random oversampling
- Simple de implementar
- Aplicable a cualquier clasificador
- Ampliamente validado en la literatura

Desventajas

- Amplifica ruido y outliers
- Puede generar solapamiento entre clases
- No aplica a variables categóricas directamente
- Sensible a K y alta dimensionalidad
- No considera la distribución de la clase mayoritaria

¿Cuándo usar SMOTE?

Escenario	Recomendación
Desbalance moderado (1:5–1:100)	SMOTE es una buena opción
Pocos datos minoritarios (< 10)	Cost-sensitive learning
Ruido/solapamiento alto	Borderline-SMOTE o ADASYN
Variables categóricas	SMOTE-NC o SMOTE-N
Desbalance extremo (1:1000+)	Combinar SMOTE + undersampling
Suficientes datos	Ajuste de pesos en el modelo

Referencias

- Chawla, N.V., Bowyer, K.W., Hall, L.O. & Kegelmeyer, W.P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. JAIR, 16, 321–357.
- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd ed. Springer.

UTEC Posgrado

UTEC Posgrado